Автоматическая векторизация циклов: проблемы, энергоэффективность и производительность на процессорах Intel

Ольга Владимировна Молдованова 1,2

Михаил Георгиевич Курносов 1,2

ovm@sibguti.ru, ovm@isp.nsc.ru

WWW: www.mkurnosov.net

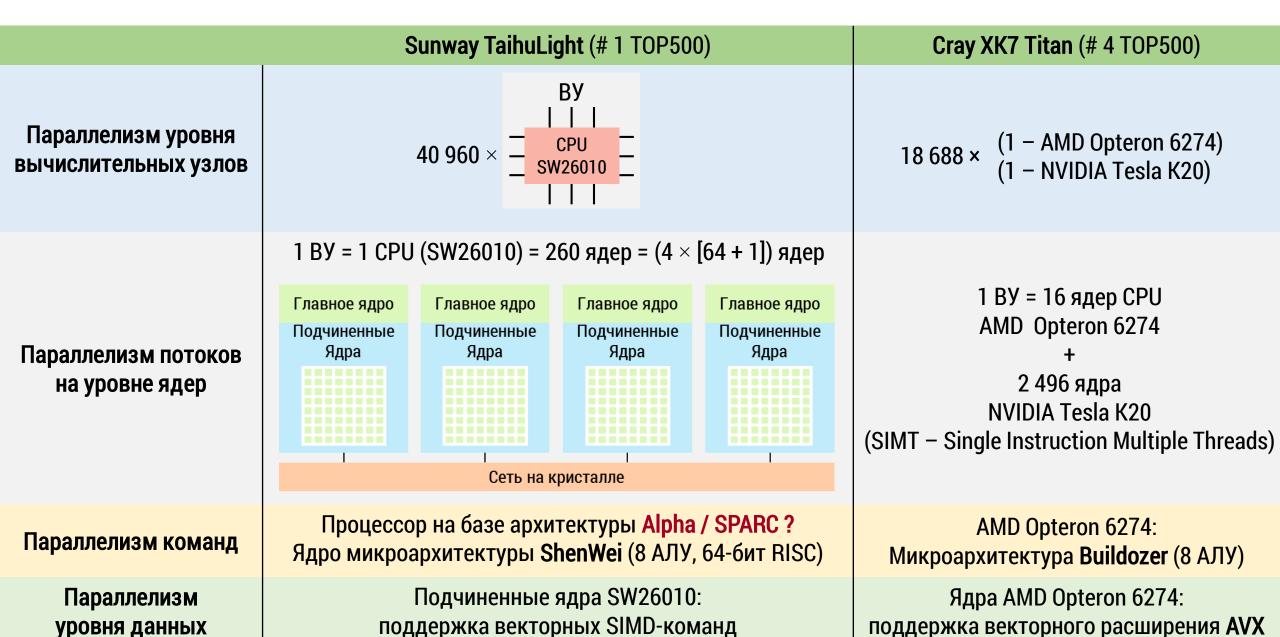
¹ Кафедра вычислительных систем Сибирский государственный университет телекоммуникаций и информатики, Новосибирск

² Лаборатория вычислительных систем Институт физики полупроводников им. А.В. Ржанова СО РАН, Новосибирск

Международная конф еренция «Суперкомпьютерные дни в России» г. Москва, 25-26 сентября 2017 г.



Вычислительные системы с иерархическим параллелизмом



SIMD-инструкции процессоров

• Наборы векторных инструкций

- Intel MMX/SSE/AVX/AVX-3, AVX-512
- IBM AltiVec
- ARM NEON SIMD
- MIPS MSA

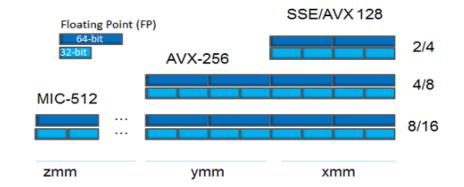
• Достигаемые ускорения

Тип данных	Intel SSE (регистры 128 бит)	Intel AVX (регистры 256 бит)	Intel AVX-512 (регистры 512 бит)	ARMv8 Scalable Vector Extension (регистры 128-2048 бит, RIKEN Post-K supercomputer, 2020)
double	х2	х4	8 x	x32
float	х4	х8	x16	x64
int	х4	х8	x16	x64
short int	х8	x16	x32	x128

• Причины снижения ускорения

- Адреса массивов не выравнены на заданную границу (32 байта для AVX и 64 байта для AVX-512)
- Смешанное использование SSE- и AVX-инструкций (AVX-SSE Transition Penalties) [1]

Векторные регистры (Intel 64, Intel Xeon Phi)



Способы векторизации кода

• Ассемблерные вставки

■ **Интринсики (intrinsics)** — встроенные функции и типы данных компилятора

■ SIMD-директивы компиляторов, стандартов OpenMP, OpenACC

```
void add_sse(float *a, float *b, float *c) {
    __asm__ __volatile__ (
        "movaps (%[a]), %%xmm0 \n\t"
        "movaps (%[b]), %%xmm1 \n\t"
        "addps %%xmm1, %%xmm0 \n\t"
        "movaps %%xmm0, %[c] \n\t"
}
```

```
void add_sse(float *a, float *b, float *c) {
    __m128 t0, t1;
    t0 = _mm_load_ps(a);
    t1 = _mm_load_ps(b);
    t0 = _mm_add_ps(t0, t1);
    _mm_store_ps(c, t0);
}
```

```
void f(double *a, double *b, double *c, int n)
{
    #pragma omp simd
    for (int i = 0; i < n; i++)
        c[i] += a[i] * b[i];
}</pre>
```

- Языковые расширения (Intel Array Notation, Intel ISPC, Apple Swift SIMD)
 и библиотеки (C++17 SIMD, Boost.SIMD, SIMD.js)
- Автоматическая векторизация компилятором

```
$ gcc -ftree-vectorize ./vec.c
vec.c:13:5: note: loop vectorized
vec.c:18:5: note: not vectorized, possible dependence between data-refs
```

Набор тестовых циклов

1991

TSVC – Test Suite for Vectorizing Compilers [1]
 (122 цикла на Fortran)

Векторные ВС: Cray, NEC, IBM, DEC, Fujitsu, Hitachi

2011

ETSVC – Extended Test Suite for Vectorizing Compilers [2, 3]
 (151 цикл на С)

Наборы векторных инструкций: Intel SSE/AVX, IBM AltiVec, ARM NEON SIMD, MIPS MSA

Категория	Число циклов
Анализ зависимостей по данным (dependence analysis)	36
Анализ потока управления и трансформация циклов (vectorization)	52
Распознавание идиоматических конструкций (idiom recognition)	27
Полнота понимания языка программирования (language completeness)	23
Контрольные циклы (control loops)	13

- [1] Levine D., Callahan D., Dongarra J. A Comparative Study of Automatic Vectorizing Compilers // Journal of Parallel Computing. 1991. Vol. 17. pp. 1223–1244.
- [2] Maleki S., Gao Ya. Garzarán M.J., Wong T., Padua D.A. **An Evaluation of Vectorizing Compilers** // Proc. of the Int. Conf. on Parallel Architectures and Compilation Techniques (PACT-11), 2011. pp. 372–382.
- [3] Extended Test Suite for Vectorizing Compilers. URL: http://polaris.cs.uiuc.edu/~maleki1/TSVC.tar.gz

```
#define TYPE float
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
#ifdef MIC
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][LEN2];
int s000() {
                                                          Каждый цикл – отдельная функция (всего 151 функция)
    init("s000 ");
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1;
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                   TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
#ifdef MIC
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][LEN2];
int s000() {
    init("s000 ");
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                   TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                       LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][LEN2];
int s000() {
    init("s000 ");
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                   TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                       LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
                                                       ntimes – количество повторений внешнего цикла
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][LEN2];
int s000() {
    init("s000 ");
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                    TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                       LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
                                                       ntimes – количество повторений внешнего цикла
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
                                                                                     Выравнивание адресов
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
                                                                                     массивов на заданную
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][L
                                                                                     границу
int s000() {
    init("s000 ");
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                    TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                       LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
                                                       ntimes – количество повторений внешнего цикла
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
                                                                                     Выравнивание адресов
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
                                                                                     массивов на заданную
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][L
                                                                                     границу
int s000() {
    init("s000 ");
                                                      Инициализация массивов значениями, характерными для теста
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                    TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                        LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
                                                        ntimes – количество повторений внешнего цикла
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
                                                                                      Выравнивание адресов
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
                                                                                     массивов на заданную
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][L
                                                                                     границу
int s000() {
    init("s000 ");
                                                      Инициализация массивов значениями, характерными для теста
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
                                                                                      Увеличение времени
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
                                                                                     выполнения теста
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0) (формирование статистики)
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    return 0;
```

```
#define TYPE float
                                                    TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                        LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
                                                        ntimes – количество повторений внешнего цикла
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
                                                                                      Выравнивание адресов
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
                                                                                      массивов на заданную
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][L
                                                                                      границу
int s000() {
    init("s000 ");
                                                      Инициализация массивов значениями, характерными для теста
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
                                                                                      Увеличение времени
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
                                                                                      выполнения теста
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0) (формирование статистики)
    clock_t end_t = clock();
                                                                                      Предотвращение
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
                                                                                      нежелательной
    check(1);
                                                                                      оптимизации внешнего
    return 0;
                                                                                      цикла
```

```
#define TYPE float
                                                     TYPE – тип данных массивов: double, float, int, short int
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
                                                        LEN, LEN2 — размеры одномерных и двумерных массивов
#ifdef MIC
                                                        ntimes – количество повторений внешнего цикла
    #define ALIGN 64
#else
    #define ALIGN 32
#endif
                                                                                      Выравнивание адресов
__attribute__ ((aligned(ALIGN))) TYPE X[LEN], Y[LEN], Z[LEN], U[LEN], V[LEN];
                                                                                      массивов на заданную
__attribute__ ((aligned(ALIGN))) TYPE aa[LEN2][LEN2], bb[LEN2][LEN2], cc[LEN2][L
                                                                                      границу
int s000() {
    init("s000 ");
                                                      Инициализация массивов значениями, характерными для теста
    clock_t start_t = clock();
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
                                                                                      Увеличение времени
        for (int i = 0; i < LEN; i++)</pre>
            X[i] = Y[i] + 1:
                                                                                      выполнения теста
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0) (формирование статистики)
    clock_t end_t = clock();
                                                                                      Предотвращение
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
                                                                                      нежелательной
    check(1);
                                                                                      оптимизации внешнего
    return 0;
                  Вычисление контрольной суммы элементов итогового массива
                                                                                      цикла
```

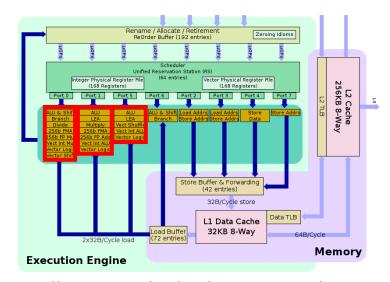
Целевые архитектуры: Intel 64 и Intel Xeon Phi

Двухпроцессорный NUMA-сервер

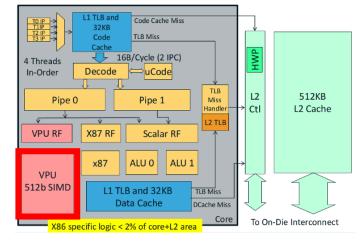
- 2 процессора Intel Xeon E5-2620 v4: архитектура Intel 64, микроархитектура Broadwell, 8 ядер, Hyper-Threading включен, группа векторных АЛУ с поддержкой AVX 2.0
- Память: 64 GiB, DDR4,
- Операционная система: GNU/Linux CentOS 7.3 x86-64 (ядро linux 3.10.0-514.2.2.el7)

Сопроцессор Intel Xeon Phi 3120A

- **57 ядер** с микроархитектурой Intel Knights Corner: in-order, 4-way SMT, SIMD Unit: 1 векторная AVX-512 операция за такт, 32 векторных регистра, vector gather/scatter, IEEE 754 2008
- Память: 6 GiB
- Программное обеспечение: MPSS 3.8



https://en.wikichip.org/wiki/intel/microarchitectures/broadwell



http://semiaccurate.com/2012/08/28/intel-detailsknights-corner-architecture-at-long-last/

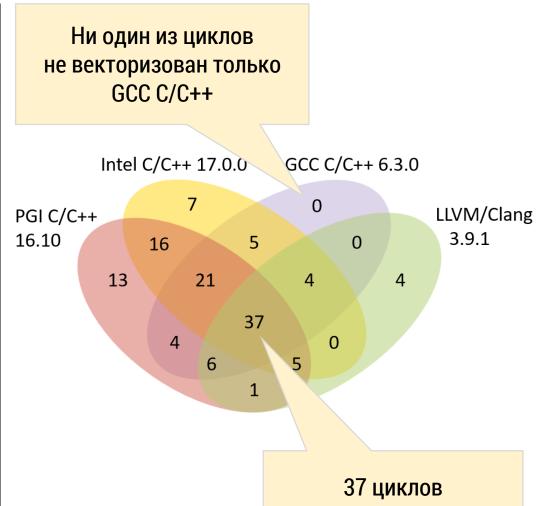
Целевые компиляторы

Компилятор	Опции компиляции	Отключение векторизатора
Intel C/C++ 17.0	-03 -xHost -qopt-report3 -qopt-report-phase=vec,loop -qopt-report-embed	-no-vec
GCC C/C++ 6.3.0	-03 -ffast-math -fivopts -march=native -fopt-info-vec -fopt-info-vec-missed -fno-tree-vectorize	-fno-tree-vectorize
LLVM/Clang 3.9.1	-03 -ffast-math -fvectorize -Rpass=loop-vectorize -Rpass-missed=loop-vectorize -Rpass-analysis=loop-vectorize	-fno-vectorize
PGI C/C++ 16.10 Community Edition	-03 -Mvect -Minfo=loop,vect -Mneginfo=loop,vect	-Mnovect

Результаты экспериментов

Количество автоматически векторизованных циклов

Компиляторы	Число циклов, векторизованных <u>только</u> указанными компиляторами
Intel C/C++, GCC C/C++, LLVM/Clang, PGI C/C++	37
Intel C/C++, GCC C/C++, LLVM/Clang	4
Intel C/C++, GCC C/C++, PGI C/C++	21
Intel C/C++, LLVM/Clang, PGI C/C++	5
GCC C/C++, LLVM/Clang, PGI C/C++	6
Intel C/C++, GCC C/C++	5
Intel C/C++, LLVM/Clang	0
Intel C/C++, PGI C/C++	16
GCC C/C++, PGI C/C++	4
GCC C/C++, LLVM/Clang	0
LLVM/Clang, PGI C/C++	1
Intel C/C++	7
GCC C/C++	0
LLVM/Clang	4
PGI C/C++	13



векторизовано всеми

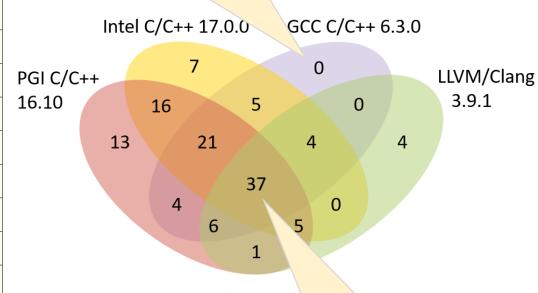
компиляторами

Количество автоматически векторизованных циклов

Компиляторы	Число циклов, векторизованных <u>только</u> указанными компиляторами								
Intel C/C++, GCC C/C++, LLVM/Clang, PGI	C/C++ 37								
Intel C/C++, GCC C/C++, LLVM/Clang	4								
Intel C/C++, GCC C/C++, PGI C/C++	21								
Intel C/C++, LLVM/Clang, PGI C/C++	5								
GCC C/C++, LLVM/Clang, PGI C/C++	6								
Intel C/C++, GCC C/C++	5								
Intel C/C++, LLVM/Clang	0								
Intel C/C++, PGI C/C++	16								
GCC C/C++, PGI C/C++	4								
GCC C/C++, LLVM/Clang	0								
LLVM/Clang, PGI C/C++	1								
Intel C/C++	7								
GCC C/C++	(10 F 0)								
LLVM/Clang	28 циклов (18,5 %) не ве								

PGI C/C++

Ни один из циклов не векторизован только GCC C/C++



8 циклов (18,5 %) не векторизованы ни одним из компиляторов!

37 циклов векторизовано всеми компиляторами

Результаты автоматической векторизации циклов (Intel 64, тип данных double)

Цикл векторизован

Невозможно вычислить количество он Значение не может быть

	V	кл ве іност		ризо	ван				М	Мультиверсионность											NI	Невозможно вычислить количество итераций												Значение не может быть использовано за пределами цикла															
		кл ве		ризо	ван	час	ГИЧЬ	10	во	Неподходящая операция									CF	Невозможно определить												Векторизатор не может понять																	
	KV I	гаток			ie				AP	Сл	ОЖН	ΙЫЙ	ша	блон	н до			<u> </u>			SS	Ц	ИКЛ	не	под	ход	ит д	цля E	ект	орн	ой		SW	поток управления в цикле Наличие оператора switch															
	вен	стори	130B	ан										ассі торс		e Ma	тже	т бн	JTh			36	апи	си п	о не	СМ	НЖ	ым а	адре	ecan	M			ВЦ	ИКЛ	5								-	ı	Цик.	л S:	235	
		стори не эф				ЭЖН	a,		R	ид	енти	ифи	цир	ова поль	но к	как	рез	уль	гат		ME							и вь			1		US			церж жен		емо	е и	СПО)ЛЬ3(эваі	ние			KTO GCC	-		Н
		висим Эпятс						1	IL		-			счет яетс							FC	И	ли д	цанн	•	кот	орь	зовь ые не		-			GS			иров				рац	ий з	апи	1СИ						
	I	CC	V	IF V	7 IF	V	V	D	V	V	V	V	D	V	D	V	D	D	V	V	D	V	V	V	V	D	V	D	D	V	M :	D [V	V	D	V	V	V	V	PV	V	PV	М	DI	F V	7 V	PV	PV	PV
		GI	V	IF V	J V	V	V	D	V	V	V	D	V	V	V	V	NI	D	D	V	D	V	D	V	V	D	FC	FC	D	V	D :	D N	I V	V	NI	V	D	D	D	D	D	D	V	D II	F V	<i>y</i> V	V	D	D
	LLV		V	IF V	7 D	V	D	D	D	D	IF		R	V	V	V	NI	CF	CF	V	R	IF	IF	V	V	R	V	V	CF (CF	V .	VN	I V	V	NI	V	R	R	R -	R	V	R	R	R II	FR	R	R	D -	R
		CC	<u> </u>	V \	/ ∨	\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \	\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \	\ \ \ \	BO	\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \	AP	D	1 1 1	V	V	V	NT	SS	V	V	AP	\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \	V	\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \	V	TT	\	M	M	M	M C	V N	V	V	NI	۷	D	D	<u>м</u>	D	<u> </u>	D	<u> </u>	<u>СТ</u> Т		M M	V 10	ם	D
_	Ци	кл:	2000	\$111	S1112 S112	S1112	S113	S1113	S114	S115	S1115	S116	S118	S119	S1119	S121	S122	S123	S124	S125	S126	S127	S128	S131	S132	S141	S151	S152	S161	S1161	S162	21/12	S173	S174	S175	S176	S211	S212	S1213	S221	\$1221	2222	S231	\$232	51232	S223	\$23	S241	S247
	I	cc	PV	PV P	V V	V	V	D	V	V	V	V	D	D	D	D	V	V	V	V	V	V	PV	V	D	V	V	V	V	V	V	J C	V	V	D	IF	PV	D	V	IF	V	V	V	IF V	J V	7 V	V	D	V
		GI		D I			V	V	V	V	V	V	V	_	D	V	D	V	V	V	V	D	V	IF	D	V	V					V C		V	D	IF	V	V	V	FC	V	V	V	V V	7 V	7 V	V	V	V
	LLV		V	D I		V	V	R	V	V	CF	V	R	R	OL	R	R	CF	CF	CF	CF	R	IF V	UV	CF	CF	CF	CF (D V	R	R	D	IF	IF	R	V	FC	V	V	V	R V	/ V	R	V	R	V
	G	CC	D	D I			V	US	V	US	V	FC	US	AP	ВО	US	D	V		\ \ \ \	\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \	CF.	•	۷	D D	M	CF	CF	•		V '	V \	US	08	\ \ \ \	115	T F	D	V	FC	V	<u> </u>	V (ID V		US		V	V
			S243	S244	S2244	S251	\$1251	\$2251	S3251	S252	\$253	S254	S255	S256	S257	S258	S261	S271	S272	S273	S274	S275	S2275	S276	S277	S278	S279	S1279	S2710	S2711	52712	5281	S291	S292	S293	S2101	S2102	S2111	S311	S31111	S312	5313	S314	\$315	531b	S318	S319	S3110	S13110
		CC	V	D V	D	D	D	V	ME	D	D	D	V	V	V	IF	V	V	М	М	М	V	V ,	/ V	7 V	7 V	V	V	ME	ME	IF	V	IF	V	7 V	V	V	V	V	IF	V	V	V	V	V	J V	V	V	V
	P	GI	V	V V	D	D	D	V	ME	V	V	V	V	V	V	IF	V	V	V	V	V	V ,	∨ '	7 V	7 V	' II	F V	V	FC	ME	V	V	IF	D 7	7 V	V	V	V	IF	V	V	V	V	V	V	JV	V	V	V
	LLV		R	R V		R	R	R	UV	CF	CF	CF	IF	_	_			V	-	-			EF S	W C	F V	7 V			UV	NI	IF	_	_	F I	_		V	FC	IF	IF	CF	V	V		V V	JV	V	V	V
	G	cc	V	JS V		D	D	US	CF	SS	US	SS	V			20		V		<u> </u>	•	V	CF C	F			V		CF	CF	SS	V		V V		V	V	CF	V	SS	V	V	V	V /				V	V
			S3111	S3112 S3113	S321	S322	S323	5331	5332	S341	S342	S343	S351	S1351	S352	S353	S421	S1421	S422	S423	S424	5431	2441	2442	\$451	\$452	\$453	S461	S481	S482	S491	\$4112	\$4113	S4114 C411E	\$4116	\$4117	\$4121	va	vag	vas	vif	vdv	vtv	vpvtv	vpvts	vpvpv	vsumr	vdotr	vbor

Результаты автоматической векторизации циклов (Intel Xeon Phi, тип данных double)

V	Цикл векторизован полностью	М	Мультиверсионность	NI	Невозможно вычислить количество итераций	0L	Значение не может быть использовано за пределами цикла
PV	Цикл векторизован частично	во	Неподходящая операция	CF	Невозможно определить направление потока управления	UV	Векторизатор не может понять поток управления в цикле
RV	Остаток цикла не векторизован	AP	Сложный шаблон доступа к элементам массива	SS	Цикл не подходит для векторной записи по несмежным адресам	SW	Наличие оператора switch в цикле
IF	Векторизация возможна, но не эффективна	R	Значение, которое не может быть идентифицировано как результат редукции, используется вне цикла	ME	Цикл с несколькими выходами невозможно векторизовать	US	Неподдерживаемое использование в выражении
D	Зависимость по данным препятствует векторизации	IL	Переменная-счетчик внутреннего цикла не является инвариантом	FC	Цикл содержит вызовы функций или данные, которые невозможно проанализировать	GS	В базовом блоке нет сгруппированных операций записи

Intel C/C++ Compiler 17.0 (-mmic) native mode

double	V	V	V	V	V	V	D	V	V	V	PV	D	V	D	V	D	D	V	V	D	V	V	V	V	D	V	D	D	V	M 1	D I	7 (7 V	D	V	V	V	V	PV	RV	PV	М	D	IF	V	V	PV	PV	D
float	V	V	V	V	V	V	D	V	V	V	PV	D	V	D	V	D	D	V	V	D	V	V	V	V	D	V	D	D	V	M	DI	7 (7 V	D	V	V	V	V	PV	PV	PV	М	D	V	V	V	PV	PV	PV
	2000	S111	S1111	S112	S1112	S113	S1113	S114	S115	S1115	S116	S118	S119	S1119	S121	S122	S123	S124	S125	S126	S127	S128	S131	S132	S141	S151	S152	S161	S1161	S162	21/12	2172	5174	\$175	S176	S211	S212	S1213	S221	S1221	S222	S231	S232	S1232	S233	S2233	S235	S241	S242
double	PV	PV	PV	V	V	V	D	V	V	V	V	D	D	D	D	V	V	V	V	V	V	PV	V	D	V	V	V	V	V	V	7 D	7 \	7 V	D	V	PV	7 D	V	IF	V	V	V	V	V	V	V	V	D	V
float	PV	PV	PV	V	V	V	D	V	V	V	V	D	D	D	D	V	V	V	V	V	V	PV	V	D	V	V	V	V	V	V	7 D	7 \	7 V	D	V	PV	7 D	V	IF	V	V	V	V	V	V	V	V	D	V
	S243	S244	S1244	S2244	S251	\$1251	\$2251	S3251	S252	S253	S254	S255	S256	S257	S258	S261	S271	S272	S273	S274	S275	S2275	S276	S277	S278	S279	S1279	S2710	S2711	52712	2281	212.01	7070	5293	S2101	S2102	S2111	S311	S31111	S312	S313	S314	S315	S316	S317	S318	S319	S3110	S13110
double	V	D	V	D	D	D	V	ME	V	V	V	V	PV	V	V	V	V	М	М	M	V V	7 V	J	/ V	7 V	V	V	ME	ME	V	V	V	PV	V	V	7	V V	7	7 V	V	V	V	V	V	V	V	V	V	V
float	V	D	V	D	D	D	V	ME	V	V	V	V	V	V	V	V	V	М	М	М	V V	7 V	J	7 V	7 V	v V	V	ME	ME	V	V	V	V	V	V	7	V	7	7 V	. \	V	V	V	V	V	V	V	V	V
	33111	S3112	3113	S321	S322	S323	5331	S332	S341	S342	S343	S351	1351	5352	5353	S421	1421	S422	S423	S424	2431	2441	2442	S451	\$452	S453	S461	S481	S482	S491	S4112	S4113	S4114	S4115	54116	2411/	4121	מאל לא	Vas	. vif	λdλ	· t	vpvtv	vpvts	vpvpv	vtvtv	vsumr	vdotr	vbor

Классы невекторизованных циклов

Классы невекторизованных циклов

Категория / Подкатегория	Общее число циклов	Число невекторизованных циклов
Анализ зависимостей по данным (dependence analysis)	36	9
Линейная зависимость по данным (linear dependence)	14	2
Распознавание индуктивной переменной (induction variable recognition)	8	3
Нелинейная зависимость (nonlinear dependence)	1	1
Условные и безусловные переходы (control flow)	3	1
Переменные в границах цикла или шаге выполнения итераций (symbolics)	6	2
Анализ потока управления и трансформация циклов (vectorization)	52	11
Расщепление тела цикла (loop distribution)	3	2
Перестановка циклов (loop interchange)	6	2
Расщепление вершин в графе зависимостей по данным (node splitting)	6	4
Растягивание скаляров и массивов» (scalar and array expansion)	12	2
Условные и безусловные переходы (control flow)	14	1
Распознавание идиоматических конструкций (idiom recognition)	27	6
Рекуррентности (recurrences)	3	3
Поиск элемента в массиве (search loops)	2	1
Свертка цикла (loop rerolling)	4	1
Редукции (reductions)	15	1
Полнота понимания языка программирования (language completeness)	23	2
Прерывание вычислений в цикле» (nonlocal GOTO)	2	2

Подкатегория «Линейная зависимость по данным» (linear dependence)

Невекторизованный цикл s1113

```
for (int i = 0; i < N; i++)
    X[i] = X[N/2] + Y[i];</pre>
```

 Зависимость по данным вида «чтение после записи» (read-after-write, RAW), начиная с итерации N/2+1

Раскрутка цикла s1113 по итерациям

```
X[0] = X[N/2] + Y[0];
X[1] = X[N/2] + Y[1];
...

X[N/2] = X[N/2] + Y[N/2];
X[N/2+1] = X[N/2] + Y[N/2+1];
...

X[N-1] = X[N/2] + Y[N-1];
```

Подкатегория «Линейная зависимость по данным» (linear dependence)

Невекторизованный цикл s1113	Возможная трансформация цикла s1113
<pre>for (int i = 0; i < N; i++) X[i] = X[N/2] + Y[i];</pre>	int k = N / 2;
	<pre>for (int i = 0; i <= k; i++) X[i] = X[k] + Y[i];</pre>
	<pre>for (int i = k + 1; i < N; i++) X[i] = X[k] + Y[i];</pre>

■ Зависимость по данным вида «чтение после записи» (read-after-write, RAW), начиная с итерации *N*/ 2 + 1

- Распределение путем разбиения имен (fission by name)
- Ускорение в 2 раза для типа double и компилятора ICC на Intel Xeon E5-2620 v4

Подкатегория «Распознавание индуктивной переменной» (induction variable recognition)

```
Невекторизованный цикл s126
                                          Возможная трансформация цикла s126
int k = 1;
for (int i = 0; i < N; i++) {
                                       for (int j = 1; j < N; j++) {
    for (int j = 1; j < N; j++) {
                                           for (int i = 0; i < N; i++) {
                                                X[j][i] = X[j - 1][i] +
        X[j][i] = X[j - 1][i] +
                                                          Y[i * 4 + j - 1] *
                  Y[k - 1] *
                  Z[j][i];
                                                          Z[i][i];
        ++k;
                               Шаг = N
```

- Индуктивная переменная k
- Внешний цикл осуществляет проход по столбцам матриц X и Z, а внутренний − по строкам

- Перестановка циклов и удаление индуктивной переменной к
- Ускорение в **8.5** раз для типа double и компилятора ICC на Intel Xeon E5-2620 v4

Подкатегория «Условные и безусловные переходы» (control flow)

Невекторизованный цикл s161

```
for (int i = 0; i < N - 1; ++i)
{
    if (Y[i] < 0)
        goto L20;

    X[i] = Z[i] + V[i] * W[i];
    goto L10;

L20: Z[i + 1] = X[i] + V[i] * V[i];
L10: ;
}</pre>
```

Раскрутка цикла s161 по итерациям

```
i = 0:
       if (Y[0] < 0)
      Z[1] = X[0] + V[0] * V[0];
      else 🔪
S_2^0:
         X[0] = Z[0] + V[0] * W[0];
i = 1:
                              S_1\delta_{<}S_2
       if (Y[1] < 0)
         Z[2] = X[1] + V[1] * V[1];
S_1^1:
       else
S_2^1:
      X[1] = Z[1] + V[1] * W[1];
```

Возможная зависимость выражения S_2 на итерации i- то выражения S_1 на итерации i- 1 вида «чтение после записи» (read-after-write, RAW)

Подкатегория «Переменные в границах цикла или шаге выполнения итераций» (symbolics)

```
Невекторизованный цикл s172

void s172(int n1, int n3)
{
    for (int i = n1 - 1; i < N; i += n3)
        X[i] += Y[i];
}
```

Переменные, используемые в качестве нижней и(или) верхней границы цикла и(или) шага выполнения итераций

Категория «Анализ потока управления и трансформация циклов» (vectorization)

Подкатегория «Растягивание скаляров и массивов» (scalar and array expansion)

- Зависимость выражения S_1 на итерации iот S_1 на итерации i- 1 вида «чтение после записи» (read-after-write)
- Зависимость выражения S_2 на итерации i от S_1 на той же итерации вида «чтение после записи» (read-after-write)
- Зависимость выражения S_2 на итерациях i, j от S_1 на тех же итерациях вида «запись после чтения» (write-after-read)

- Расщепление тела цикла (loop fission, loop distribution)
- Ускорение в **9.3** раза для типа double и компилятора ICC на Intel Xeon E5-2620 v4

Категория «Распознавание идиоматических конструкций» (idiom recognition)

Подкатегория «Рекуррентности» (recurrences)

Зависимость выражения S_1 на итерации iот выражения S_1 на итерациях i-1 и i-2 вида «чтение после записи» (read-after-write, RAW)

Категория «Распознавание идиоматических конструкций» (idiom recognition)

Подкатегория «Свертка цикла» (loop rerolling)

```
Невекторизованный цикл s353
void s353(int* __restrict__ ip) {
    double alpha = Z[0];
    for (int i = 0; i < N; i += 5) {
        X[i] += alpha * Y[ip[i]];
        X[i+1] += alpha * Y[ip[i+1]];
        X[i+2] += alpha * Y[ip[i+2]];
        X[i+3] += alpha * Y[ip[i+3]];
        X[i+4] += alpha * Y[ip[i+4]];
```

Косвенная адресация при обращении к элементам массива Y[ip[i]]

Категория «Распознавание идиоматических конструкций» (idiom recognition)

Подкатегория «Редукции» (reductions)

Невекторизованный цикл s31111

```
double test(double* A) {
    double s = (double)0.;
    for (int i = 0; i < 4; i++)
        s += A[i]:
    return s:
void s31111() {
    double sum;
    for (int i = 0; i < N; i++) {
        sum = (double)0.;
        sum += test(X);
        sum += test(&X[4]);
        sum += test(&X[8]);
        sum += test(&X[12]);
        sum += test(&X[16]);
        sum += test(&X[20]);
        sum += test(&X[24]);
        sum += test(&X[28]);
```

Наличие вызова функции в теле цикла

Категория «Полнота понимания языка программирования» (language completeness)

Подкатегория «Прерывание вычислений в цикле» (nonlocal GOTO)

Невекторизованный цикл s481

exit(0);

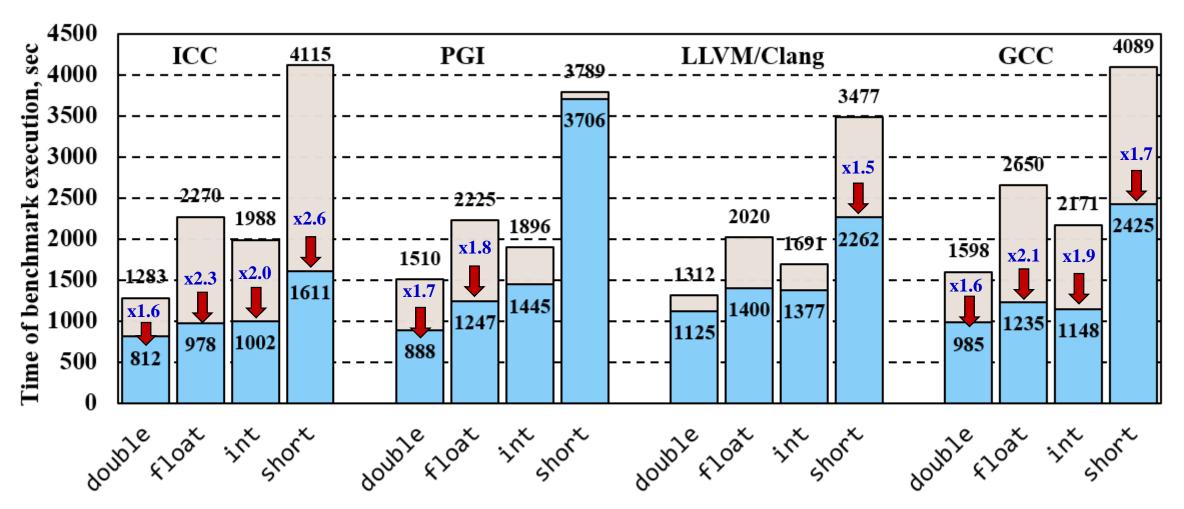
X[i] += Y[i] * Z[i];

for (int i = 0; i < N; i++) { if (V[i] < (double)0.)</pre>

Наличие вызова функции exit в теле цикла

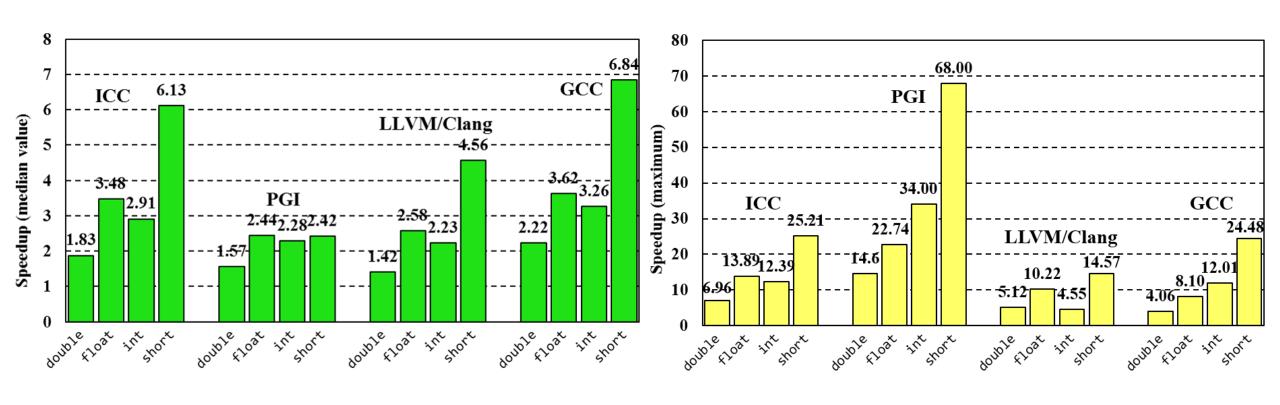
Сокращение времени выполнения векторизованных циклов

Время выполнения векторизованных циклов на процессоре Intel Xeon E5-2620 v4



Суммарное время выполнения теста (всех циклов) для типов данных double, float, int u short int

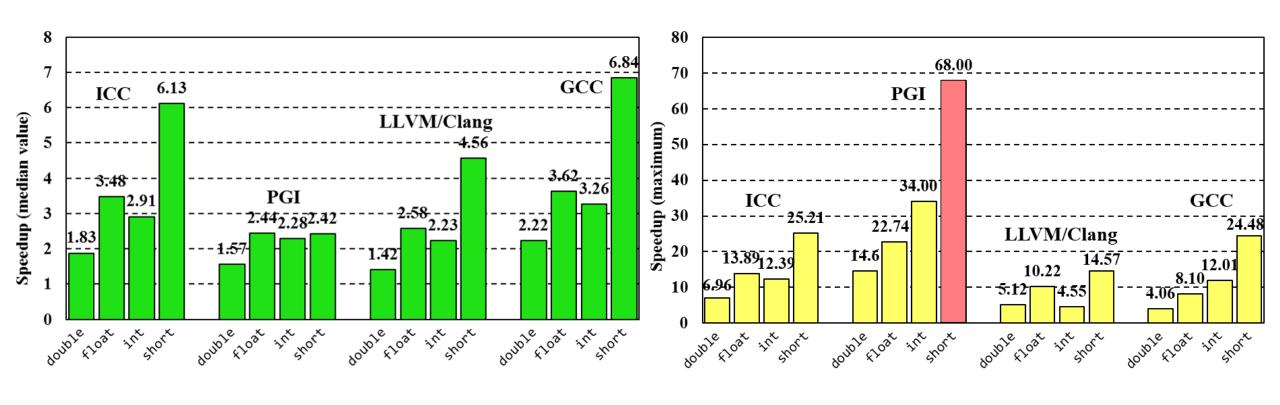
Ускорение выполнения векторизованных циклов на процессоре Intel Xeon E5-2620 v4



Медиана ускорения

Максимальное ускорение

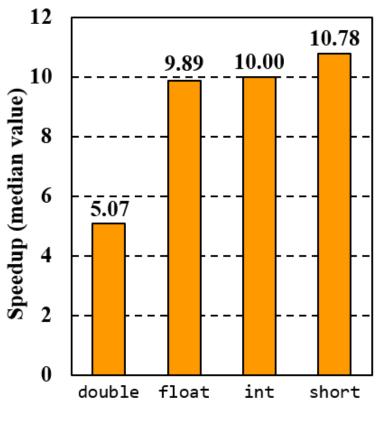
Ускорение выполнения векторизованных циклов на процессоре Intel Xeon E5-2620 v4



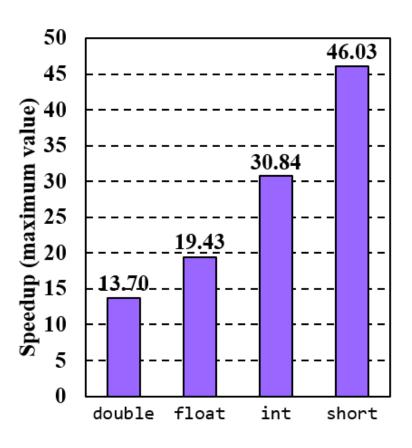
Медиана ускорения

Вычисления в цикле не производились в результате оптимизации

Ускорение выполнения векторизованных циклов на сопроцессоре Intel Xeon Phi 3120A (Intel C/C++ 17.0)



Медиана ускорения



Максимальное ускорение

Влияние векторизации на энергопотребление процессора

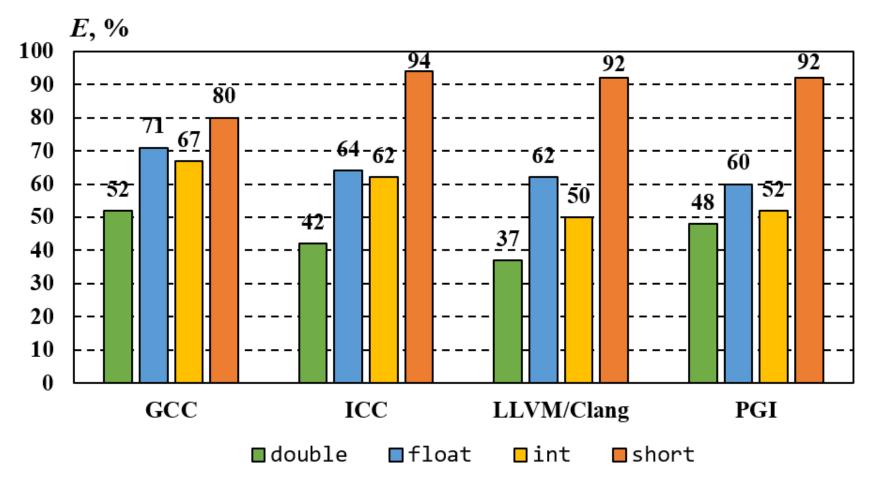
Измерение энергопотребления процессора Intel Xeon E5-2620 v4

```
#define TYPE float
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
struct RaplMultiPackageInfo rapl_ctx;
                                                     Измерение энергопотребления процессора при помощи обращений к
                                                            подсистеме Intel RAPL (Running Average Power Limit)
int s000() {
    init("s000 ");
    clock_t start_t = clock();
    raplPackageMultiCpuStartMeasure(&rapl_ctx);
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)
            X[i] = Y[i] + 1:
        dummy((TYPE*)X, (TYPE*)Y, (TYPE*)Z, (TYPE*)U, (TYPE*)V, aa, bb, cc, 0.0);
    raplPackageMultiCpuStartMeasure(&rapl_ctx);
    clock_t end_t = clock();
    printf("S000\t %.2f \t\t", (double)((end_t - start_t)/1000000.0));
    check(1);
    raplPackageMultiCpuPrint(&rapl_ctx);
    return 0:
```

Измерение энергопотребления процессора Intel Xeon E5-2620 v4

```
#define TYPE float
#define LEN (125 * 1024 / sizeof(TYPE))
#define LEN2 256
#define ntimes 200000
struct RaplMultiPackageInfo rapl_ctx;
                                                       Измерение энергопотребления процессора при помощи обращений к
                                                              подсистеме Intel RAPL (Running Average Power Limit)
int s000() {
    init("s000 ");
    clock_t start_t = clock();
    raplPackageMultiCpuStartMeasure(&rapl_ctx);
    for (int nl = 0; nl < 2 * ntimes; nl++) {</pre>
        for (int i = 0; i < LEN; i++)
                                  Сокращение энергопотребления процессора:
    rapl
                                    E = (E_{novec} - E_{vec}) / E_{novec} \cdot 100\%
    cloc
    prin
    chec
         где E_{novec} – энергопотребление процессора при выполнении невекторизованной версии цикла (Дж),
    rapl
               E_{vec} – энергопотребление процессора при выполнении векторизованной версии цикла (Дж)
    retu
```

Сокращение энергопотребления процессора Intel Xeon E5-2620v4 при выполнении векторизованного цикла относительно его невекторизованной версии



Результаты оценки (медиана) показателя *Е* только для успешно векторизованных циклов (сокращение времени выполнения не менее чем на 15% по сравнению с их невекторизованными версиями)

Спасибо за внимание!

Ольга Владимировна Молдованова 1,2

Михаил Георгиевич Курносов 1,2

ovm@sibguti.ru, ovm@isp.nsc.ru

WWW: www.mkurnosov.net

¹ Кафедра вычислительных систем Сибирский государственный университет телекоммуникаций и информатики, Новосибирск

² Лаборатория вычислительных систем Институт физики полупроводников им. А.В. Ржанова СО РАН, Новосибирск

Международная конф еренция «Суперкомпьютерные дни в России» г. Москва, 25-26 сентября 2017 г.



Сравнение результатов с предыдущими работами

2011 г. [<mark>1</mark>]		2017 г.	
Intel C/C++ 12.0	90 циклов (59.6 %)	Intel C/C++ 17.0	95 циклов (62.9 %)
GCC C/C++ 4.7.0	59 циклов (39 %)	GCC C/C++ 6.3.0	79 циклов (52.3 %)

^[1] Maleki S., Gao Ya. Garzarán M.J., Wong T., Padua D.A. **An Evaluation of Vectorizing Compilers** // Proc. of the Int. Conf. on Parallel Architectures and Compilation Techniques (PACT-11), 2011. pp. 372–382.

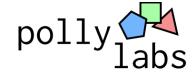
Ссылки на литературу

- 1. Maleki S., Gao Ya. Garzarán M.J., Wong T., Padua D.A. An Evaluation of Vectorizing Compilers // Proc. of the Int. Conf. on Parallel Architectures and Compilation Techniques (PACT'11), 2011. pp. 372-382.
- 2. Extended Test Suite for Vectorizing Compilers. URL: http://polaris.cs.uiuc.edu/~maleki1/TSVC.tar.gz.
- 3. Callahan D., Dongarra J., Levine D. Vectorizing Compilers: A Test Suite and Results // Proc. of the ACM/IEEE conf. on Supercomputing (Supercomputing '88), 1988. pp. 98–105.
- 4. Levine D., Callahan D., Dongarra J. A Comparative Study of Automatic Vectorizing Compilers // Journal of Parallel Computing. 1991. Vol. 17. pp. 1223–1244.
- 5. Konsor P. Avoiding AVX-SSE Transition Penalties. URL: https://software.intel.com/en-us/articles/avoiding-avx-sse-transition-penalties.
- 6. Jibaja I., Jensen P., Hu N., Haghighat M., McCutchan J., Gohman D., Blackburn S., McKinley K. Vector Parallelism in JavaScript: Language and Compiler Support for SIMD // Proc. of the Int. Conf. on Parallel Architecture and Compilation (PACT-2015). 2015. pp. 407-418.
- 7. Векторизация программ: теория, методы, реализация. Сб. статей: Пер. с англ. и нем. М.: Мир, 1991. 275 с.
- 8. Metzger R.C., Wen Zh. Automatic Algorithm Recognition and Replacement: A New Approach to Program Optimization. MIT Press. 2000. 219 p.
- 9. Rohou E., Williams K., Yuste D. Vectorization Technology To Improve Interpreter Performance // ACM Transactions on Architecture and Code Optimization. 2013. 9 (4). pp. 26:1-26:22.

Направление дальнейшей работы

 Анализ известных методов векторизации и распараллеливания циклов (полиэдральные модели: GCC Graphite, LLVM/Clang PollyLabs)





- Разработка методов векторизации установленного класса проблемных циклов из пакета ETSVC
- Анализ возможностей применения JIT-компиляции и оптимизации по результатам профилирования (profile-guided optimization)
 для автоматической векторизации кода

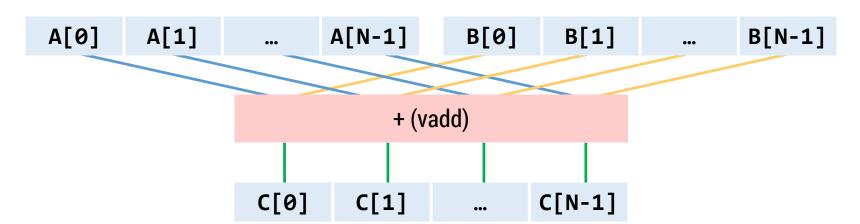
Векторизация

Скалярная операция

A[i] B[i] + (add) C[i]

Векторная операция

$$C[0..N-1] = A[0..N-1] + B[0..N-1]$$



Виды зависимостей

■ Потоковая (истинная) зависимость («чтение после записи», read-after-write, RAW)

```
for (int i = 0; i < N; i++) 

\{S_1: A[i] = B[i] + C[i]; S_1\delta = S_2 \}
\{S_2: D[i] = A[i]; S_2
```

Антизависимость («запись после чтения», write-after-read, WAR)

```
for (int i = 0; i < N; i++) 

{
S_1: A[i] = B[i] + C[i]; S_1\delta = S_2
S_2: D[i] = A[i]; S_3\overline{\delta} = S_1
S_3: S_3:
```



■ Выходная зависимость («запись после записи», write-after-write, WAW)

```
for (int i = 0; i < N; i++) 

{
S_1: A[i] = B[i] + C[i]; S_1 \delta_= S_2
S_2: A[i+1] = A[i] + D[i]; S_2 \delta_>^o S_1
```

Векторные вычислительные системы и процессоры

1970 – 1990 гг.

- Векторно-конвейерные процессоры и системы
 - CDC STAR-100, CYBER-203, CYBER-205
 - Cray 1, Cray X-MP, Cray Y-MP, NEC SX,
 IBM ViVA, Fujitsu FACOM VP, Hitachi HITAC S-810

- Длинные векторные регистры
- Ускорение x64-128 раз
- Классы векторных систем:
 - «память-память»
 - «регистр-регистр»

1995 – н. в.

- SIMD-процессоры (наборы векторных инструкций)
 - Intel MMX/SSE/AVX
 - IBM AltiVec
 - ARM NEON SIMD
 - MIPS MSA

- Короткие векторные регистры
- Ускорение х2-64 раза
- Классы векторных процессоров:
 - «регистр-регистр»